Cómo leer un backtest

Guía práctica con datos reales · FX Trading Lab · kit v1.4 · generada 2026-11-06

Material educativo. No es asesoramiento de inversión ni una recomendación de operar. Todos los números son resultados simulados sobre datos históricos; el rendimiento pasado no garantiza resultados futuros. Las hipótesis que aparecen aquí no han demostrado ninguna ventaja; se usan precisamente para enseñar a comprobarlo. Aviso completo: https://fx-trading-lab.pages.dev/legal/aviso

Esta guía usa dos versiones de una misma hipótesis intradía sobre EUR/USD durante 2024, V1 y V1.1, ejecutadas con el mismo motor, los mismos datos y los mismos costes. Una perdió. La otra ganó un poco. La pregunta de todo el documento es si esa diferencia significa algo, y cómo lo sabrías.

Qué hay en el kit

• 01 · Esta guía (ES y EN).
• 02 · Plantilla de informe de backtest, en Markdown y PDF, con las secciones que usamos en el laboratorio.
• 03 · Checklist de decisión: las preguntas que pasamos antes de creernos un número.
• 04 · Datasets: operaciones, curva de capital, métricas, sensibilidad y Monte Carlo de cada ejecución, con su SHA-256, más las instrucciones para descargar las velas M1 originales y reproducirlo todo.

Cómo usarla

Léela una vez de corrido (unos 40 minutos). Después, abre el laboratorio en el navegador, elige una ejecución y vuelve a recorrer los capítulos 2 a 8 con la pantalla delante: cada capítulo te dice exactamente qué mirar. Cuando quieras evaluar un backtest ajeno, usa la checklist del capítulo 9; cuando quieras documentar uno propio, usa la plantilla.

1. Qué es un backtest honesto (y qué no)

Un backtest es una simulación: coges unas reglas, las aplicas a datos del pasado y apuntas qué habría pasado. Es barato, rápido y por eso mismo peligroso: el ordenador te da un número con dos decimales aunque el procedimiento esté roto. Un backtest honesto cumple cuatro condiciones, y si falla una, el número no vale nada.

• **Causalidad.** En cada instante el motor solo sabe lo que ya ha cerrado. Una vela M15 no existe hasta las 09:15:00; la decisión se toma entonces y la ejecución ocurre al siguiente precio disponible, nunca al mismo.
• **Costes en cada operación.** Spread (el del proveedor si existe, si no uno fijo), deslizamiento y comisión. Sin costes, casi cualquier regla intradía parece rentable.
• **Hipótesis congelada.** Las reglas viven en un fichero con su hash. Cambiar una regla es crear otra versión (V1.1), no retocar V1 hasta que el número guste.
• **Reproducibilidad.** Hash del dataset, versión de la estrategia, configuración de ejecución, semilla, versión del software. Si otra persona no puede obtener el mismo número, no es un resultado: es una anécdota.

Las dos ejecuciones de esta guía cumplen las cuatro. Por eso sus números se pueden discutir. Lo que viene a continuación es la discusión.

Campo	Valor (V1.1, EUR/USD 2024)
Hash del dataset (SHA-256)	65a7a807004594d4a14e4408ce4abc71db1bc8f2d6c73e72a19f5ca25acde62d
Hash de la configuración	1ba09079be704d33d200276d5306ed197a93ced0b069adbc341c0eb62dccbbb3
Modelo de ejecución	first_executable_m1_price_after_bos
Deslizamiento	0.1 pips
Software	0.2.0 · source-sha256:e5bedf30a94f7bcaa37eaa733205a69121f4ac262b9649ff40e07f24f74fb81f

2. Las cinco cifras que importan

Un resumen de backtest suele traer veinte métricas. Cinco bastan para la primera lectura, y conviene mirarlas siempre en este orden.

Métrica	V1	V1.1	Qué te dice
Operaciones (N)	5	12	Cuánta evidencia hay. Todo lo demás se lee a la luz de N.
Esperanza (R por operación)	-0.52R	+0.20R	Lo que gana o pierde, de media, cada vez que arriesga 1R.
Acierto	20 %	42 %	Solo tiene sentido junto al ratio ganancia/pérdida.
Factor de beneficio	0.24	1.54	Ganancia bruta / pérdida bruta. Por debajo de 1 pierde dinero.
Drawdown máximo (R)	3.45	3.01	La peor racha, medida en unidades de riesgo, no en euros.

Por qué todo está en R

R es la distancia al stop de cada operación. Ganar +1,8R significa haber ganado 1,8 veces lo que arriesgaste en esa operación; perder -1R es perder exactamente el riesgo previsto. Medir en R hace comparables operaciones con stops distintos y quita del medio el tamaño de la cuenta y el apalancamiento, que son decisiones de otro nivel. Cuando un backtest te enseña porcentajes de rentabilidad anual, pide los R: un +40 % puede ser +4R con un 10 % de riesgo por operación, es decir, una cuenta que habría saltado por los aires en la primera mala racha.

Acierto y ratio ganancia/pérdida van juntos

V1.1 acierta el 42 % de las veces. Suena mal hasta que ves que la ganancia media es +1.34R y la pérdida media -0.62R: un ratio de 2.16. Con ese ratio, basta acertar un 32 % para no perder. La pérdida media es menor que 1R porque 5 de las 12 operaciones se cerraron por fin de sesión, no por stop: el motor no deja operaciones abiertas de un día para otro, y eso corta pérdidas pero también ganancias.

Motivo de salida	Operaciones
session expiry	5
stop loss	4
take profit	3

3. La curva de capital: qué mirar

V1.1 · R acumulado por operación (EUR/USD 2024)

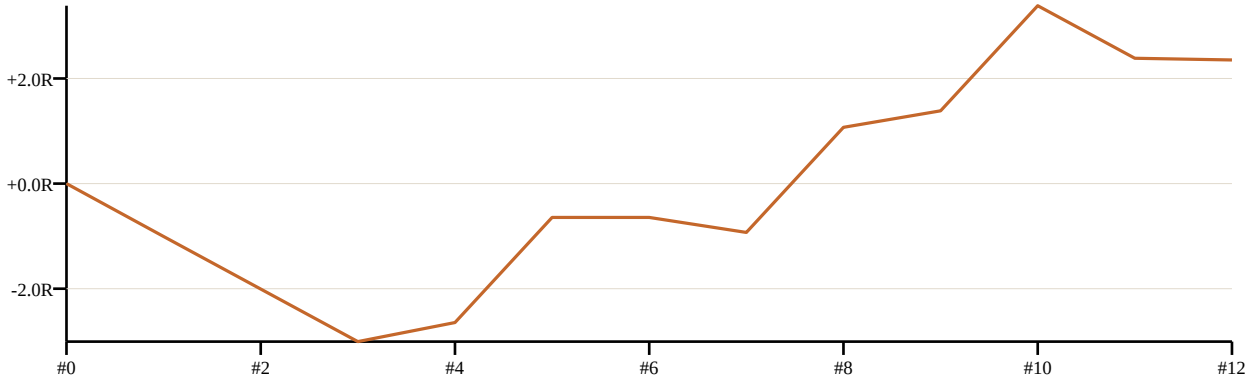

La curva de capital es la métrica más mirada y la peor leída. Tres cosas antes de sacar conclusiones:

• **El eje X son operaciones, no tiempo.** Doce escalones en doce meses. Si la curva fuera por fecha verías once meses de línea plana y un par de saltos. Ambas vistas son verdad; la segunda es más honesta sobre cuánto tiempo pasas sin hacer nada.
• **Dónde está el drawdown.** El máximo (3.01R) ocurre con 3 pérdidas seguidas. Con N = 12 eso no es una racha rara: es lo normal, como verás en el capítulo 4.
• **Cuántas operaciones explican el resultado.** Quita la mejor operación y vuelve a sumar. Si el total cambia de signo, el resultado depende de un día concreto.

Hagamos lo último con V1.1: la mejor operación fue +2.00R el 2024-04-25. Sin ella, el total pasa de +2.35R a +0.35R. Una sola operación cambia el signo del año. Apúntalo: es el dato más importante de todo el informe, y no aparece en ninguna tabla de métricas.

4. Doce operaciones no demuestran nada: Monte Carlo

Si barajas el orden de las doce operaciones de V1.1 obtienes el mismo total pero drawdowns distintos. Si en vez de barajar remuestreas (coges doce operaciones al azar de las doce, con repetición) obtienes totales distintos. Hazlo mil veces y tendrás una distribución de lo que la misma estrategia podría haber dado con la misma suerte y otra secuencia. Eso es un Monte Carlo, y su lectura es esta tabla.

Percentil	R final · V1	R final · V1.1	Drawdown máx. · V1.1
P5	-5.00R	-3.65R	1.01R
P25	-3.90R	-0.34R	2.00R
P50	-2.61R	+2.20R	2.39R
P75	-1.32R	+4.97R	3.58R
P95	+0.52R	+8.71R	5.29R
Observado	-2.61R	+2.35R	3.01R
Prob. de acabar en pérdidas	94 %	28 %	

Lee la columna de V1.1: entre P5 y P95 el resultado va de -3.65R a +8.71R. Esa es la anchura de lo que no sabes. Una estrategia que ganó +2.35R en 2024 tenía un 28 % de probabilidad de acabar el año en negativo con las mismas operaciones en otro orden o con una muestra parecida. V1 es el caso contrario: 94 % de probabilidad de perder. Ahí el Monte Carlo no te dice que V1 sea mala; te dice que, con cinco operaciones, casi cualquier cosa es compatible con lo observado.

Regla práctica. Si P25 está por debajo de cero, el backtest no ha demostrado nada todavía, gane lo que gane el caso observado. Y la anchura entre P5 y P95 solo se estrecha con más operaciones: no con más métricas, no con más gráficos.

5. ¿Lo haría igual el azar? El benchmark aleatorio

La pregunta más incómoda: ¿qué habría pasado entrando al azar dentro de las mismas ventanas horarias, con el mismo stop, el mismo objetivo, los mismos costes y la misma salida por fin de sesión? El laboratorio lo simula 200 veces. Si la estrategia no bate claramente a esas entradas aleatorias, lo que estás viendo es el comportamiento del mercado en esa hora, no la regla.

	V1	V1.1
Esperanza de la estrategia	-0.52R	+0.20R
Esperanza aleatoria · P50	-0.10R	-0.07R
Esperanza aleatoria · P95	+0.55R	+0.54R
Percentil de la estrategia frente al azar	8 %	76 %
p-valor empírico (una cola)	0.92	0.24

V1.1 queda en el percentil 76 de las entradas aleatorias: mejor que tres de cada cuatro, peor que una de cada cuatro. Un p-valor de 0.24 significa que una de cada cuatro estrategias que entran al azar lo habría hecho igual de bien. Nadie publicaría eso como evidencia en ningún campo serio. La barra habitual ($p < 0,05$) exigiría estar por encima del 95 % de las entradas aleatorias, y aun así con $N = 12$ habría que repetirlo en otro año.

Lo que sí aprendes aquí. La esperanza aleatoria mediana es negativa en las dos versiones: entrar al azar en la apertura de Londres con esos costes pierde dinero. Es la línea base contra la que hay que medir cualquier regla; sin ella, un +0,19R parece mucho y no sabes respecto a qué.

6. Fragilidad: la prueba de sensibilidad

Una regla robusta se parece a sí misma cuando mueves un parámetro un poco. Una regla frágil cambia de signo. El laboratorio reejecuta la hipótesis variando un parámetro cada vez y deja el resto fijo. Así queda V1.1:

Parámetro	Valor	N	Total R	Esperanza
target.baseline	1.5R	12	+2.35R	+0.20R
target.baseline	2.0R	12	+2.35R	+0.20R
target.baseline	2.5R	12	+3.85R	+0.32R
target.baseline	3.0R	12	+4.06R	+0.34R
slippage.baseline_pips	0.0	12	+2.46R	+0.21R
slippage.baseline_pips	0.1	12	+2.35R	+0.20R
slippage.baseline_pips	0.2	12	+2.26R	+0.19R
slippage.baseline_pips	0.5	11	+2.06R	+0.19R
risk.baseline_equity_risk_fraction	0.0025	12	+2.35R	+0.20R
risk.baseline_equity_risk_fraction	0.005	12	+2.35R	+0.20R
risk.baseline_equity_risk_fraction	0.01	12	+2.35R	+0.20R
zones.expiry_m15_bars	4	12	+2.35R	+0.20R
zones.expiry_m15_bars	8	12	+2.35R	+0.20R
zones.expiry_m15_bars	12	12	+2.35R	+0.20R
setup.lifetime_m15_bars_from_sweep_confirmation	6	9	-0.65R	-0.07R
setup.lifetime_m15_bars_from_sweep_confirmation	8	12	+2.35R	+0.20R
setup.lifetime_m15_bars_from_sweep_confirmation	12	14	+4.98R	+0.36R
displacement.minimum_atr	0.75	12	+2.26R	+0.19R
displacement.minimum_atr	1.0	12	+2.35R	+0.20R
displacement.minimum_atr	1.25	11	+3.35R	+0.30R
stop.reference	sweep_extreme	13	+0.35R	+0.03R
stop.reference	zone_distal	12	+2.35R	+0.20R
stop.reference	leg1_origin	18	-3.74R	-0.21R
stop.max_distance_atr	3.0	12	+2.35R	+0.20R
stop.max_distance_atr	4.0	17	-1.55R	-0.09R
stop.max_distance_atr	5.0	19	-1.82R	-0.10R
liquidity.level_max_age_m15_bars	None	15	+3.29R	+0.22R
liquidity.level_max_age_m15_bars	960	10	+0.04R	+0.00R
liquidity.level_max_age_m15_bars	1920	12	+2.35R	+0.20R
liquidity.level_max_age_m15_bars	3840	12	+2.35R	+0.20R
session	london_open_09:00-10:30	12	+2.35R	+0.20R
session	new_york_open_15:00-16:30	8	-6.66R	-0.83R

V1.1 · total R al cambiar un parámetro (el resto fijo)

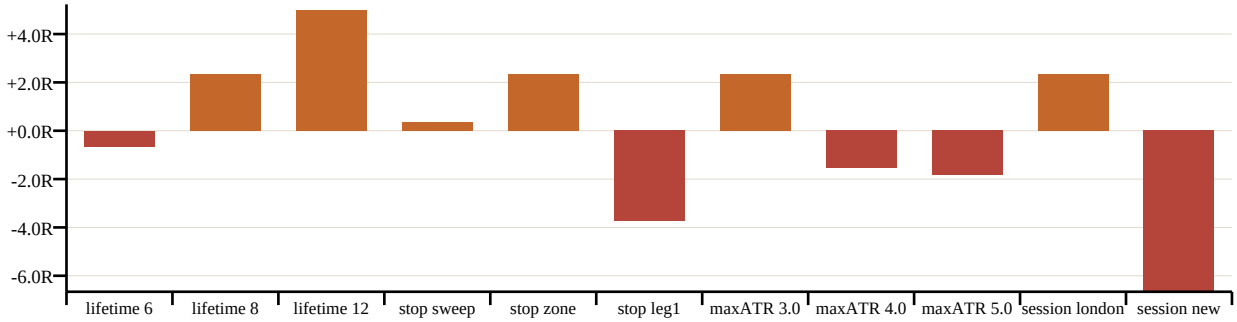

Cómo leer la tabla: busca las filas en las que el resultado cambia de signo o se multiplica.

• **stop.reference.** Con el stop en el extremo del barrido o en el origen del impulso, V1.1 pasa a ganar casi nada o a perder. El resultado positivo depende de una sola elección de stop. Es el hallazgo más importante de 2024 y por eso V1.1 existe (V1 usaba otro stop).
• **setup.lifetime.** Seis velas de vida en vez de ocho: negativo. Doce: el doble. Un parámetro que no sale de ninguna teoría decide el signo.
• **session.** La misma regla en la apertura de Nueva York pierde con claridad. No es una estrategia: es, como mucho, una observación sobre la apertura de Londres.
• **Lo que no cambia nada** (target, riesgo por operación, expiración de zonas) tampoco es buena señal: significa que esos parámetros casi nunca intervienen con doce operaciones.

Regla práctica: si al mover un parámetro un paso el total cambia de signo, apunta ese parámetro en el log de decisiones como *no resuelto* y no optimices sobre él. Optimizar un parámetro frágil con doce operaciones es ajustar ruido.

7. Fuera de muestra: particiones y walk-forward

Todo lo anterior se calcula sobre el año completo, que es también el año en el que se diseñó la regla. La única manera de saber si una regla aguanta datos que no vio es reservar un tramo y no tocarlo hasta el final. El laboratorio hace dos cosas: una partición cronológica (entrenamiento, validación y fuera de muestra) y un walk-forward con ventanas rodantes.

Tramo (V1.1)	Días	N	Total R	Esperanza
train	158	8	+1.07R	+0.13R
validation	53	3	+1.31R	+0.44R
out of sample	52	1	-0.03R	-0.03R

Walk-forward (fuera de muestra concatenado)	V1	V1.1
Operaciones	3	6
Total R	-0.66R	+3.00R
Ventanas con operaciones / positivas	3 / 1	4 / 2
Consistencia	33 %	50 %

El tramo fuera de muestra de V1.1 tiene 1 operación. Una. No se puede concluir nada, y eso es exactamente lo que hay que escribir en el informe. El walk-forward da 6 operaciones fuera de muestra con 2 ventanas positivas de 4: una moneda al aire. Una estrategia intradía con doce operaciones al año necesita varios años de datos solo para que la partición fuera de muestra tenga sentido. Es el motivo por el que el siguiente paso del laboratorio es 2022-2023, no otra métrica.

8. Costes: de positivo a negativo

Deslizamiento (pips)	N	Total R	Esperanza
0.0	12	+2.46R	+0.21R
0.1	12	+2.35R	+0.20R
0.2	12	+2.26R	+0.19R
0.5	11	+2.06R	+0.19R

Aquí V1.1 se comporta bien: pasar de 0 a 0,5 pips de deslizamiento resta unos 0,4R en doce operaciones, porque el stop está lejos (varios ATR) y los costes son pequeños en relación al riesgo. En estrategias con stops de pocos pips la misma tabla suele cambiar de signo en la segunda fila. Pide siempre esta tabla; si no existe, asume el peor caso.

Tres preguntas sobre costes que hay que poder responder leyendo el informe: ¿de dónde sale el spread (histórico del proveedor o un número fijo)? ¿Se aplica el deslizamiento también al stop? ¿La comisión está en la misma unidad que el riesgo?

9. La checklist de decisión

Doce preguntas. Si alguna de las cinco primeras falla, deja de leer el informe. Si fallan dos de las restantes, el veredicto es *todavía no sabemos*, que es el veredicto de casi todos los backtests honestos.

- 1. ¿Están publicados el hash del dataset, la versión de la estrategia y la configuración de ejecución?
- 2. ¿El motor decide solo con velas cerradas y ejecuta al siguiente precio?
- 3. ¿Hay spread, deslizamiento y comisión en cada operación, y se dice de dónde salen?
- 4. ¿Las reglas estaban escritas antes de ver el resultado (fichero con hash, versión nombrada)?
- 5. ¿Se puede reproducir el número con el código y los datos indicados?
- 6. ¿Cuántas operaciones hay? ¿Qué pasa con el total si quitas la mejor?
- 7. Monte Carlo: ¿P25 está por encima de cero? ¿Cuál es la probabilidad de acabar en pérdidas?
- 8. Benchmark aleatorio: ¿la estrategia supera al 95 % de las entradas al azar con los mismos costes?
- 9. Sensibilidad: ¿algún parámetro cambia el signo del total al moverlo un paso?
- 10. Fuera de muestra: ¿hay un tramo reservado con operaciones suficientes para decir algo?
- 11. Costes: ¿el resultado sobrevive a 0,5 pips más de deslizamiento?
- 12. ¿El informe termina con una decisión de investigación (descartar, seguir, nueva versión) y no con una invitación a operar?

La checklist está también como fichero aparte (03-checklist) para imprimirla o pegarla al final de cada informe.

10. Cómo contar un resultado (sobre todo si es negativo)

Un informe de backtest no es un folleto. Su trabajo es que otra persona pueda rehacerlo y discrepar con datos. La plantilla del kit (02-plantilla) tiene estas secciones, en este orden, y cada una tiene un motivo:

• **Hipótesis y versión.** Qué regla, en qué fichero, con qué hash. Qué cambió respecto a la versión anterior y por qué (enlace al log de decisiones).
• **Datos.** Proveedor, símbolo, rango, zona horaria, hash, huecos y filas inválidas.
• **Ejecución y costes.** Modelo de relleno, spread, deslizamiento, comisión, riesgo por operación.
• **Resultado.** Las cinco cifras, la curva en R, los motivos de salida. Y el total sin la mejor operación.
• **Protocolo.** Monte Carlo, benchmark aleatorio, sensibilidad, particiones y walk-forward, cada uno con su tabla.
• **Limitaciones.** Las que ya sabes y las que te ha enseñado el protocolo.
• **Decisión.** Una de tres: descartar, seguir investigando (con qué dato nuevo), o pasar a la siguiente versión (con qué cambio exacto). Nunca *operar*: eso no es una decisión de investigación.

Un resultado negativo bien documentado vale más que uno positivo sin protocolo: te ahorra repetir el error y le ahorra a otros creerse el número. V1 perdió; de su informe salió el hallazgo del stop y, de ahí, V1.1. Esa cadena, y no el +2,35R, es el producto del laboratorio.

11. Glosario

Término	Significado
R	Unidad de riesgo: la distancia al stop de cada operación. +2R = dos veces el riesgo asumido.
Esperanza	R medio por operación. Positiva no significa rentable si N es pequeño.
Factor de beneficio	Suma de ganancias / suma de pérdidas (en valor absoluto).
Drawdown	Caída desde el máximo anterior de la curva de capital, aquí en R.
MFE / MAE	Máxima excursión favorable / adversa de una operación antes de cerrarse, en R.
Monte Carlo	Remuestreo de las operaciones para ver la distribución de resultados posibles.
Benchmark aleatorio	Entradas al azar con las mismas reglas de salida y costes; la línea base contra la que se mide la regla.
Sensibilidad	Reejecución cambiando un parámetro cada vez.
Walk-forward	Ventanas rodantes: se ajusta en una y se evalúa en la siguiente, sin solapar.
Fuera de muestra	Tramo de datos reservado que no se usa para diseñar ni ajustar la regla.
Look-ahead	Usar información que todavía no existía en el momento de decidir. Invalida el backtest.
Hash (SHA-256)	Huella del fichero. Si cambia un byte, cambia el hash: permite saber que dos personas usaron los mismos datos.

12. Reproducir estos números

Todo el código es público. Los datasets del kit (04-datasets) contienen las operaciones, la curva, las métricas, la sensibilidad y el Monte Carlo de cada ejecución, con el SHA-256 de cada fichero. Las velas M1 originales no se incluyen porque pertenecen al proveedor; el fichero COMO-DESCARGAR-DATOS.md explica cómo bajarlas con el script del repositorio y comprobar que su hash coincide con el de esta guía.

Recurso	URL
Laboratorio (gratis)	https://fx-trading-lab.pages.dev
Código	https://github.com/inigogonzalezgarcia/9999-trading-lab
Aviso legal y método	https://fx-trading-lab.pages.dev/legal/aviso

13. Epílogo: lo que pasó en 2022 y 2023

Los capítulos anteriores se escribieron con 2024 y terminaban con una promesa: la respuesta estaba en más años, no en más métricas. Aquí está la respuesta. Misma regla V1.1, mismo motor, mismos costes (spread fijo de 0,3 pips porque los datos de 2022-2023 no traen columna de spread; en 2024 la mediana real fue 0,2).

Año	N	Total R	Esperanza	Acierto	Percentil vs azar	Prob. de perder (MC)
2019	5	-0.84R	-0.17R	40 %	45 %	63 %
2020	15	-0.10R	-0.01R	40 %	51 %	52 %
2021	7	+3.86R	+0.55R	71 %	94 %	11 %
2022	11	-8.01R	-0.73R	18 %	1 %	100 %
2023	4	-0.29R	-0.07R	25 %	52 %	62 %
2024	12	+2.35R	+0.20R	42 %	76 %	28 %
2025	10	-0.96R	-0.10R	50 %	46 %	62 %
2026	3	+1.94R	+0.65R	67 %	86 %	14 %
8 años	67	-2.04R	-0.03R			

2022 es la respuesta completa: 11 operaciones, -8.01R, 9 de ellas cerradas por stop, peor que el 99 % de las entradas aleatorias con las mismas salidas y costes. Ningún parámetro de la tabla de sensibilidad lo rescata: todas las variantes de stop, vida del setup y distancia máxima quedan entre -6,8R y -10,9R. El «hallazgo del stop» del capítulo 6 era un hallazgo de 2024, no de la regla.

Vuelve al capítulo 4 y mira la columna de 2024: P25 por debajo de cero, 28 % de probabilidad de perder, percentil 75 frente al azar. El protocolo ya decía «todavía no sabemos». Lo que hacen 2022 y 2023 es convertir ese «no sabemos» en «no». Esa es la secuencia normal de una hipótesis honesta, y por eso el informe de 2024 no decía «operar».

• **Decisión registrada.** V1.1 se descarta como mejora de V1 y se mantiene publicada como ejemplo de falso positivo. No se deriva ninguna V1.2 de 2024.
• **Regla nueva para el laboratorio.** Ninguna hipótesis se lee sobre un año suelto: primero los tres años juntos, después cada año por separado para ver la dispersión.
• **Para tu propio backtest.** Si solo tienes un año, lo que tienes es un capítulo 4. Pide el segundo año antes de creerte nada, y espera que sea peor.

Material educativo. No es asesoramiento de inversión. El rendimiento pasado no garantiza resultados futuros.